

1 KF 公式推导

假设一离散线性动态系统的模型如下所示,

$$x_k = A * x_{k-1} + B * u_k + w_{k-1} \quad (1)$$

$$z_k = H * x_k + v_k \quad (2)$$

其中, x_k 为系统状态矩阵, z_k 为系统状态的观测矩阵, A 为系统转移矩阵, B 为控制输入矩阵, H 为状态观测矩阵, w_{k-1} 为过程噪声且其协方差为 Q , v_k 为测量噪声且其协方差 R 。

对于状态估计算法, 可以获取状态量的三个值, 真实值 x_k , 状态预测值 \hat{x}_k^- 也称先验状态估计值, 状态最优估计 \hat{x}_k 也称后验状态估计值。卡尔曼滤波器的原理是利用卡尔曼增益来修正状态预测值, 使其逼近真实值。

接下来本文将在此基础上推导卡尔曼滤波器。

状态预测值 \hat{x}_k^- 可通过状态预测方程可得,

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_k \quad (3)$$

状态最优估计值 \hat{x}_k 可通过状态更新方程可得,

$$\hat{x}_k = \hat{x}_k^- + K * (z_k - H * \hat{x}_k^-) \quad (4)$$

通过该方程可知, 卡尔曼增益 K 实际上表征了状态最优估计过程中模型预测误差与量测误差的比重。即 $K \in [0,1]$, 当 $K = 0$ 时, 预测误差为 0, 系统的状态值等于预测值, 也即 $\hat{x}_k = \hat{x}_k^-$; 当 $K = 1$ 时, 即测量误差为 0, 系统状态完全取决于测量值, 式中 $z_k - H * \hat{x}_k^-$ 称为测量创新(measurement innovation), 或者残差, 反应了测量值与预测值之间的差异, 若为 0 则意味着两者一致, 测量误差为 0。

因此, 可令,

$$e_k^- = x_k - \hat{x}_k^- \quad (5)$$

$$e_k = x_k - \hat{x}_k \quad (6)$$

$$P_k^- = E[e_k^- * e_k^{-T}] \quad (7)$$

$$P_k = E[e_k * e_k^T] \quad (8)$$

其中, e_k^- 为先验状态误差, e_k 为后验状态误差, P_k^- 真实值与预测值之间的协方差, P_k 真实值与最优估计值之间的协方差。

由(2)(4)可知,

$$\hat{x}_k = \hat{x}_k^- + K(Hx_k + v_k - H\hat{x}_k^-)$$

$$\hat{x}_k = \hat{x}_k^- + KHx_k - KH\hat{x}_k^- + Kv_k$$

$$\hat{x}_k - x_k = \hat{x}_k^- - x_k + KH(x_k - \hat{x}_k^-) + Kv_k \quad (9)$$

联立(5)(6)(9)可得,

$$e_k = (I - KH)e_k^- - Kv_k$$

由(8)可得,

$$P_k = E[e_k * e_k^T] = (I - KH)P_k^-(I - KH)^T + KRK^T$$

$$P_k = P_k^- - KHP_k^- - P_k^-H^TK^T + K(HP_k^-H^T + R)K^T \quad (10)$$

卡尔曼滤波的估计原则就是使最优状态估计的协方差 [公式] 最小, 使其越来越逼近于真实值。因此, 其目标函数为,

$$J = \sum_{min} P_k$$

对卡尔曼增益矩阵 K 求偏导, 可得,

$$\frac{\partial P_k}{\partial K} = -2(P_k^- H^T) + 2K(HP_k^- H^T + R) = 0$$

最优估计条件下的卡尔曼增益矩阵 K 的表达式,

$$K = P_k^- H^T (HP_k^- H^T + R)^{-1} \quad (11)$$

联立(9)(10)可得真实值与预测值之间的协方差矩阵为,

$$P_k = (I - KH) P_k^- \quad (12)$$

由(5)可知,

$$\begin{aligned} e_{k+1}^- &= x_{k+1} - \hat{x}_{k+1}^- = (Ax_k + Bu_k + w_k) - (A\hat{x}_k + Bu_k) \\ e_{k+1}^- &= A(x_k - \hat{x}_k) + w_k = Ae_k + w_k \end{aligned}$$

由(7)可知,

$$\begin{aligned} P_{k+1}^- &= E[e_{k+1}^- * e_{k+1}^{-T}] = E[(Ae_k + w_k)(Ae_k + w_k)^T] \\ P_{k+1}^- &= E[(Ae_k)(Ae_k)^T] + E[w_k w_k^T] \\ P_{k+1}^- &= AP_k A^T + Q \end{aligned} \quad (13)$$

至此卡尔曼滤波器 5 条公式均已推出, 分别为(3)(4)(11)(12)(13)。

$$\begin{aligned} \hat{x}_k^- &= A\hat{x}_{k-1} + Bu_k \\ P_k^- &= AP_{k-1}A^T + Q \\ K_k &= P_k^- H^T (HP_k^- H^T + R)^{-1} \\ \hat{x}_k &= \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-) \\ P_k &= (I - KH) P_k^- \end{aligned}$$

对其进行归纳可分为两个阶段, 状态预测与状态修正
状态预测包括,

$$\begin{aligned} \hat{x}_k^- &= A\hat{x}_{k-1} + Bu_k \\ P_k^- &= AP_{k-1}A^T + Q \end{aligned}$$

状态修正包括,

$$\begin{aligned} K_k &= P_k^- H^T (HP_k^- H^T + R)^{-1} \\ \hat{x}_k &= \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-) \\ P_k &= (I - KH) P_k^- \end{aligned}$$

一个工作中的卡尔曼滤波器流程示意图如 Figure 1 所示。




Figure 1 卡尔曼滤波器工作流程

2 小车轨迹预测案例

这里本文用一个小车轨迹追踪的案例介绍下卡尔曼滤波器如何应用。

假设有一辆小车，其正在 t 时刻的位置为 p_t (假设其为一维直线运动，其位置可用一个值来表示)，速度为 v_t ， t 时刻小车的状态可用向量表示为，

$$x_t = \begin{bmatrix} p_t \\ v_t \end{bmatrix}$$

假设车上传感器可获得小车的加速度为 u_t ，则该小车系统的状态预测方程可确定，

$$p_t = p_{t-1} + v_{t-1} \Delta t + u_t \frac{\Delta t^2}{2}$$
$$v_t = v_{t-1} + u_t \Delta t$$

其矩阵形式为，

$$\begin{bmatrix} p_t \\ v_t \end{bmatrix} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} p_{t-1} \\ v_{t-1} \end{bmatrix} + \begin{bmatrix} \Delta t^2/2 \\ \Delta t \end{bmatrix} u_t$$

其中，

$$A = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}, B = \begin{bmatrix} \Delta t^2/2 \\ \Delta t \end{bmatrix}$$

其协方差预测方程也可确定，

$$P_t^- = A P_{t-1} A^T + Q$$

同时在 GPS 或北斗导航系统的帮助下，可以拿到位置的观测信息 z_t ，

$$K_t = P_t^- H^T (H P_t^- H^T + R)^{-1}$$
$$\hat{x}_t = \hat{x}_t^- + K_t (z_t - H \hat{x}_t^-)$$
$$P_t = (I - K H) P_t^-$$

其中我们假设，观测矩阵 H 为，

$$H = \begin{bmatrix} 1 & 0 \end{bmatrix}$$

因为此系统中，我们仅观测位置信息，所以观测噪声的协方差为常熟，假设其为

$$R = 1$$

初始状态 x_0 为，

$$x_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

状态转移矩阵协方差 P_0 为，

$$P_0 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

过程噪声协方差 Q 定义为，

$$Q = \begin{bmatrix} 0.001 & 0 \\ 0 & 0.001 \end{bmatrix}$$

根据以上信息可以编写 Matlab 程序进行仿真，源码如 Figure 2 所示。

```

1  %卡尔曼滤波(小车[速度,位置]例子)
2  clc,clear,close all
3  %% 传感器观测
4  %-----
5  %Z = H * X + v
6  %X为t-1时刻实际状态
7  %Z为t-1时刻实际观测数据
8  %H为测量系统的参数,即观察矩阵
9  %v为观测噪声,其协方差矩阵为R
10 %-----
11 t=(1:100);
12 ut = 0;%accelertor
13 v0 = 2;%velocity
14 Z = v0*t + 1/2 * ut * t.^2;%理想观测值 (汽车的位置,也就是我们要修改的量)
15 noise=randn(1,100); %在理想观测值上叠加方差为1的高斯噪声
16 Z=Z+noise;%模拟的实际观测值
17 H=[1,0];%传感器提供的观测矩阵
18 R=1;%传感器的观测噪声协方差矩阵
19 %% 初始状态(均值)和状态协方差
20 %基于高斯分布建立状态变量需要均值和协方差(即x和P)
21 X=[0;0]; %初始状态 X=[位置;速度]
22 P=[1 0;0 1]; %状态协方差矩阵
23 %% 状态转移矩阵(表示如何由上一状态推测当前状态),它同时作用与X和P来预测下一时刻的X和P
24 A=[1 1;0 1]; %在速度例题中为[1 delta(t);0 1]
25 B=[0.5;1];%[delta(t)^2/2, delta(t)]
26 %% 外部干扰用状态转移协方差矩阵Q表示
27 Q=[0.001,0;0, 0.001];
28 %% 卡尔曼滤波
29 figure;
30 hold on;
31 for i = 1:length(Z) %迭代次数
32 %% 预测
33 X_ = A*X + B*ut;%基于上一状态预测当前状态 X_为t时刻状态预测(这里没有控制)
34 P_ = A*P*A' + Q;%更新协方差 Q系统过程的协方差
35 %% 计算卡尔曼增益
36 K = P_*H' / (H*P_*H' + R);
37 %% 更新
38 X = X_+K*(Z(i)-H*X_);% 得到当前状态的最优化估算值 增益乘以残差
39 P = (eye(2)-K*H)*P_;%更新K状态的协方差
40 %% 绘图
41 figure(1)
42 subplot(2,2,1)
43 set(0,'defaultfigurecolor','w')
44 scatter(t(i), X(1));
45 xlabel('Time'),ylabel('Position')
46 grid on
47 hold on
48 subplot(2,2,2)
49 set(1,'defaultfigurecolor','w')
50 scatter(t(i), X(2));
51 xlabel('Time'),ylabel('Vector')
52 grid on
53 hold on
54 subplot(2,2,3)
55 set(1,'defaultfigurecolor','w')
56 scatter(t(i), abs(X(1) - Z(i)));
57 xlabel('Time'),ylabel('Position Error')
58 grid on
59 hold on
60 subplot(2,2,4)
61 set(1,'defaultfigurecolor','w')
62 scatter(t(i), abs(X(2) - (v0 + ut*t(i))));
63 xlabel('Time'),ylabel('Vector Error')
64 grid on
65 hold on
66 end
67 subplot(2,2,1)
68 plot(v0*t + 1/2 * ut * t.^2, 'r','LineWidth',1)
69 subplot(2,2,2)
70 plot(v0 + ut*t, 'r','LineWidth',1)

```

Figure 2 卡尔曼滤波器在小车轨迹追踪中使用(Matlab)

其仿真结果如下,

$$v_0 = 2, u_t = 0$$

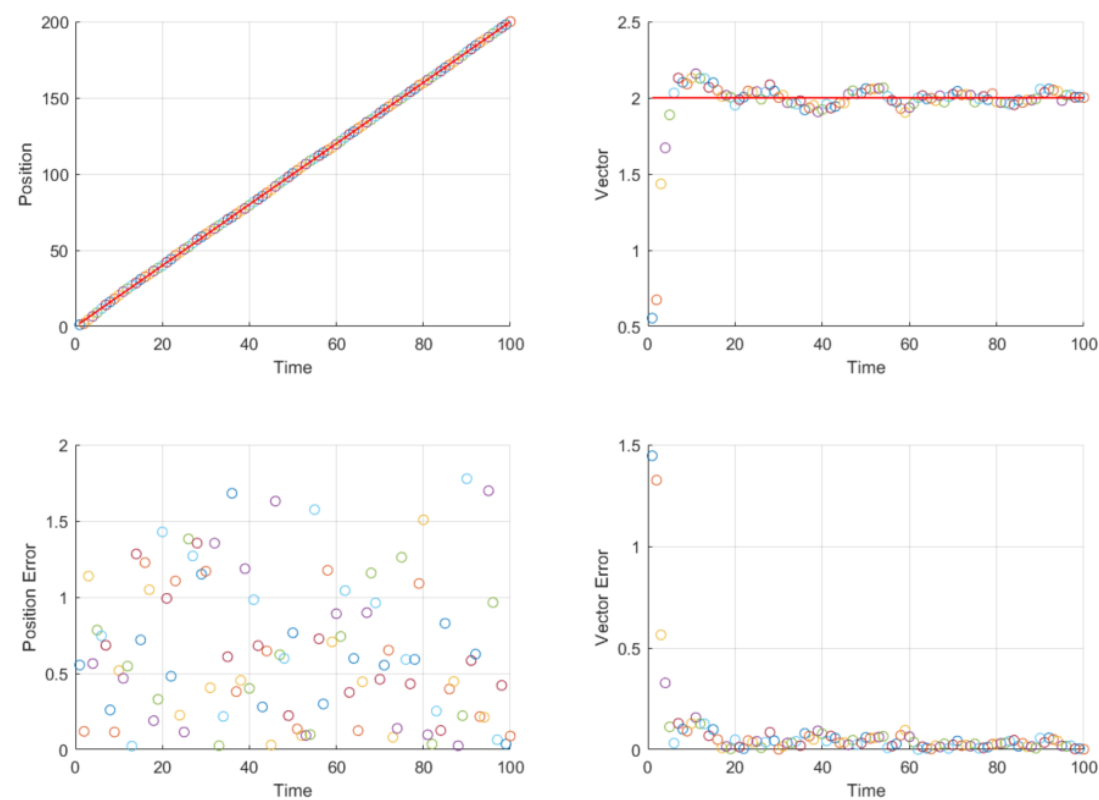


Figure 3 $v_0=2, u_t=0$ 时仿真结果

$$v_0 = 0, u_t = 1$$

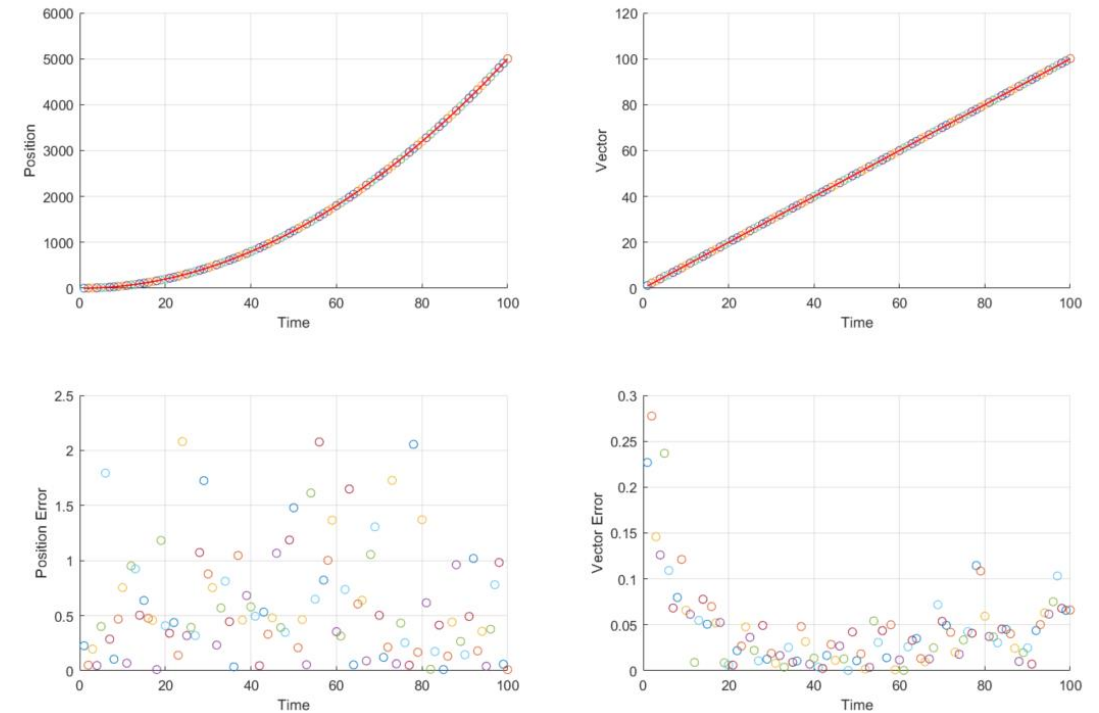


Figure 4 $v_0=0, u_t=1$ 时仿真结果

$$v_0 = 0, u_t = 10$$

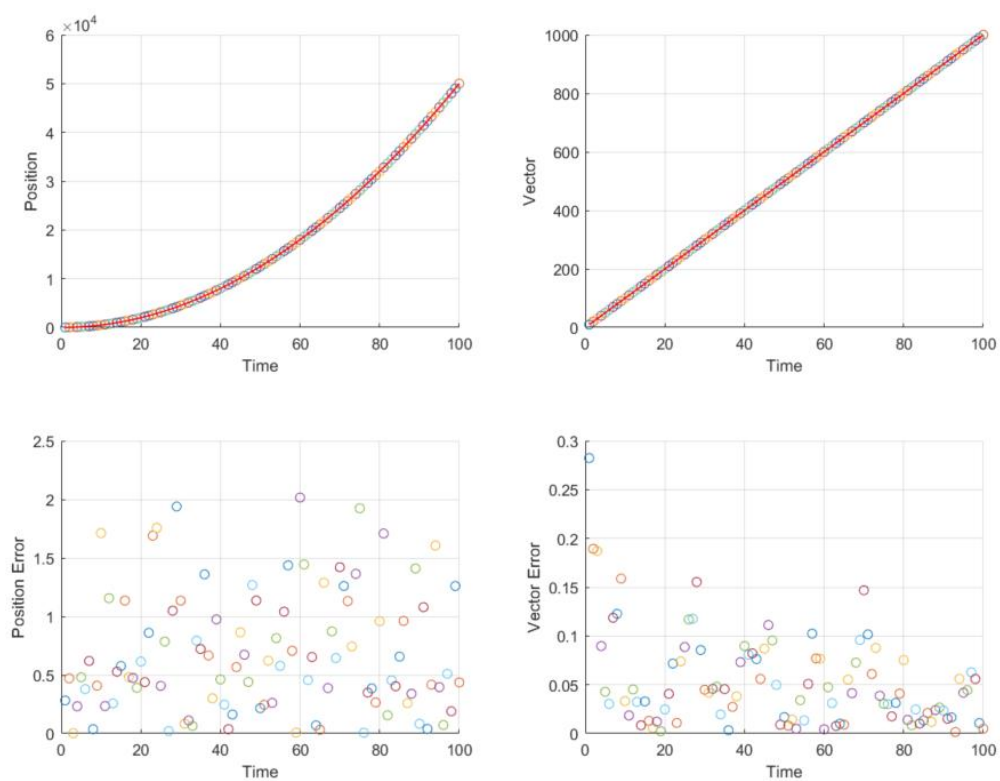


Figure 5 $v_0=0, u_t=10$ 时仿真结果